TP n°2 : Analyse Visuelle avec Seaborn

Préparation de l'environnement et des données

Exécute le code en bas pour générer un DataFrame **identique** à celui décrit dans le cours (1000 clients, villes marocaines, salaires, etc.).

Python

```python
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

# Configuration du style "moderne" recommandé dans le cours
sns.set_theme(style="whitegrid") # [cite: 45]

# --- GÉNÉRATION DES DONNÉES SYNTHÉTIQUES ---
np.random.seed(42)
n_clients = 1000

data = {
    'ID': range(1, n_clients + 1),
    'Score_Credit': np.random.normal(650, 100, n_clients).astype(int),
    'Age': np.random.randint(18, 80, n_clients),
    'Solde': np.random.uniform(0, 200000, n_clients), # Solde entre 0 et 200k MAD
    'Salaire': np.random.uniform(3000, 40000, n_clients),
    'Ville': np.random.choice(['Casablanca', 'Rabat', 'Tanger'], n_clients),
    'Genre': np.random.choice(['Homme', 'Femme'], n_clients),
    'Exited': np.random.choice([0, 1], n_clients, p=[0.8, 0.2]) # 0=Resté, 1=Parti
}

df = pd.DataFrame(data)

# Correction pour éviter les scores impossibles (300-850)
df['Score_Credit'] = df['Score_Credit'].clip(300, 850)

print("Aperçu des données :")
print(df.head())
```

Partie 1 : Analyse des Distributions (Univariée)

Exercice 1.1 : L'Histogramme et la KDE

Visualisez la répartition des soldes bancaires des clients. Utilisez une couleur teal et activez la courbe de densité (KDE).

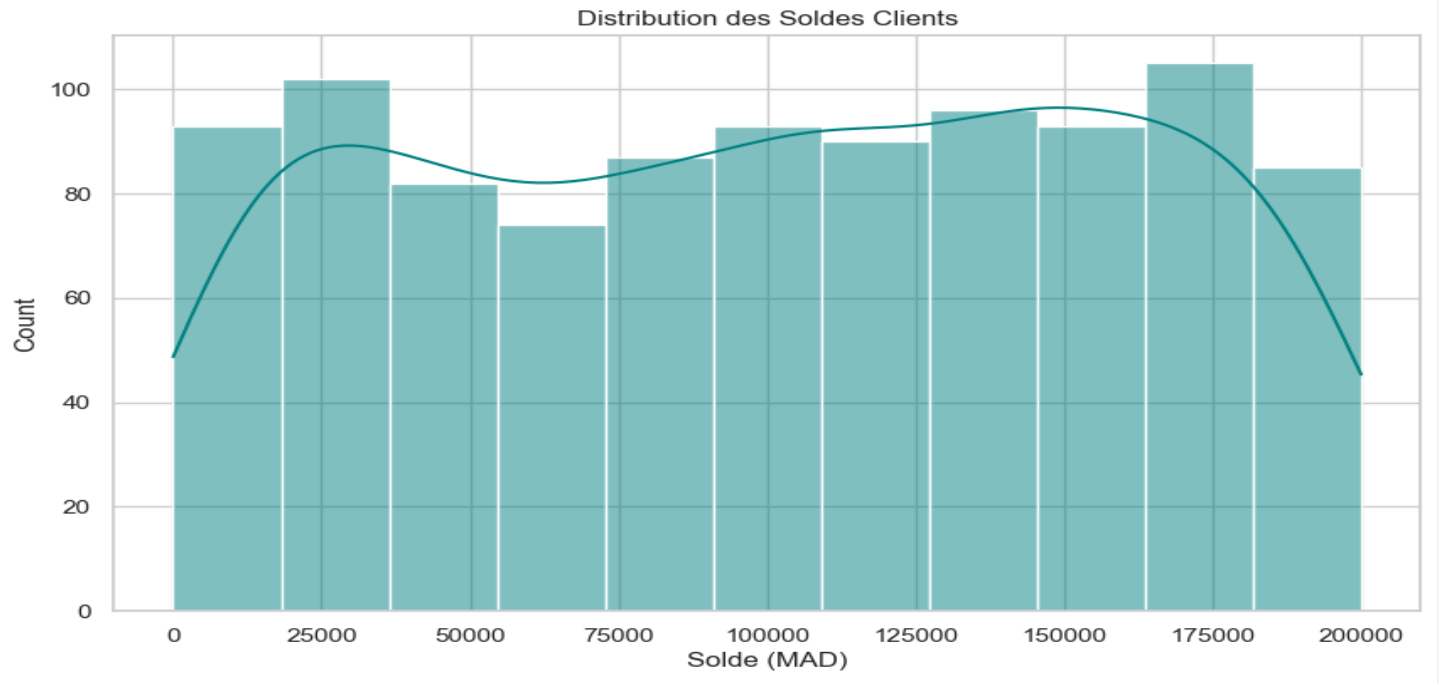

Question : Observez-vous une distribution bimodale ou uniforme ?

Exercice 1.2 : KDE Plot Comparatif (Segmentation)

Vérifiez si le Score_Credit influence le départ des clients (Exited). Superposez les densités pour les clients partis (1) et restés (0).

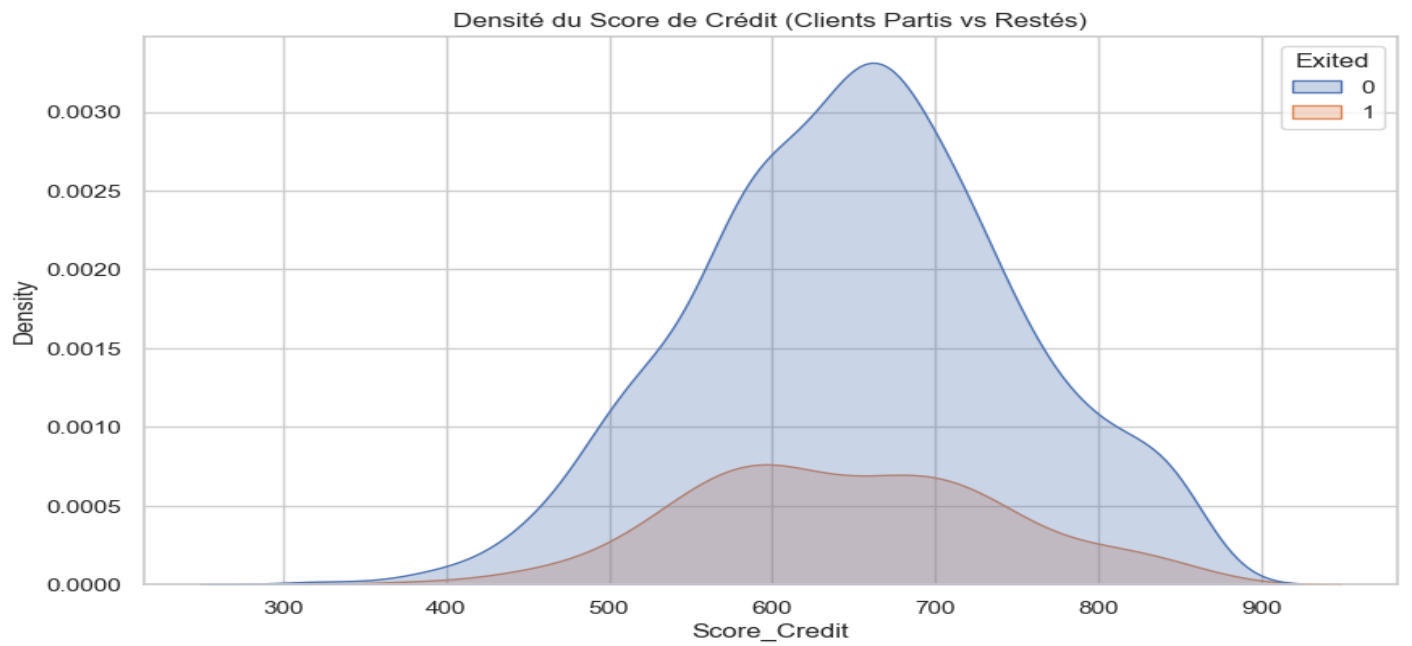

Partie 2 : Analyse des Variables Catégorielles

Exercice 2.1 : Countplot (Comparaison de volumes)

Comparez le nombre de clients partis vs restés en fonction du Genre.

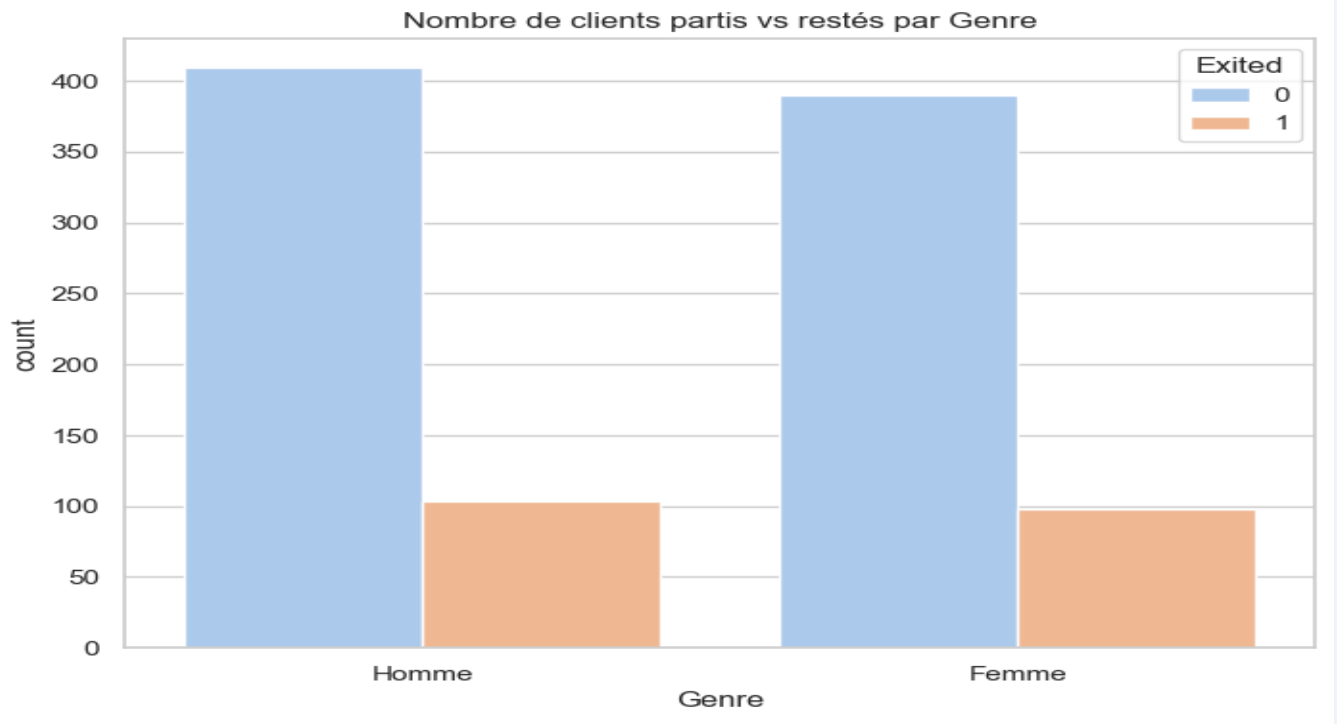

Exercice 2.2 : Boxplot (Dispersion Statistique)

Analysez la répartition des salaires par Ville. Cela permet de voir la médiane et les outliers.

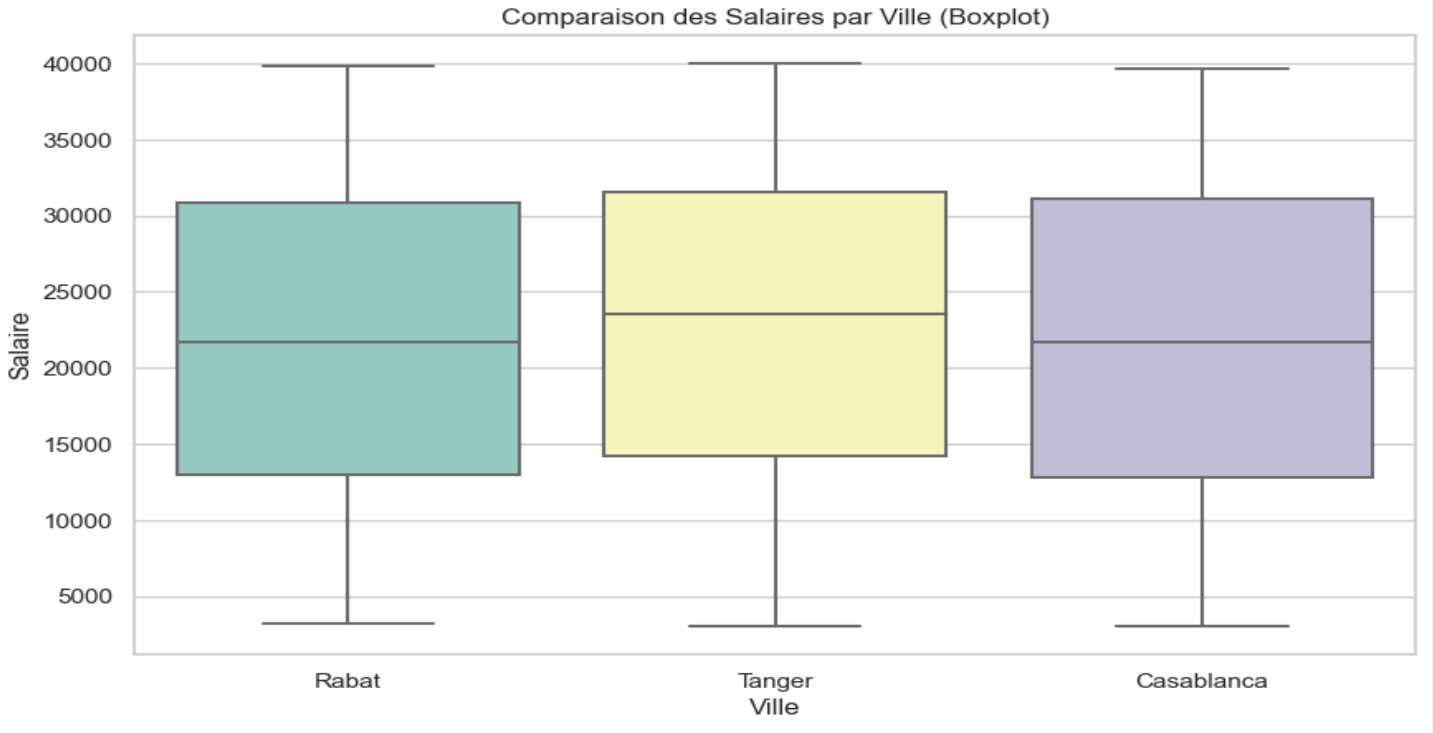

Exercice 2.3 : Violin Plot (Densité + Dispersion)

Reprenez l'analyse précédente mais avec un violinplot. Cela permet de voir si la distribution est "ventrue" (beaucoup de données au centre) ou fine.

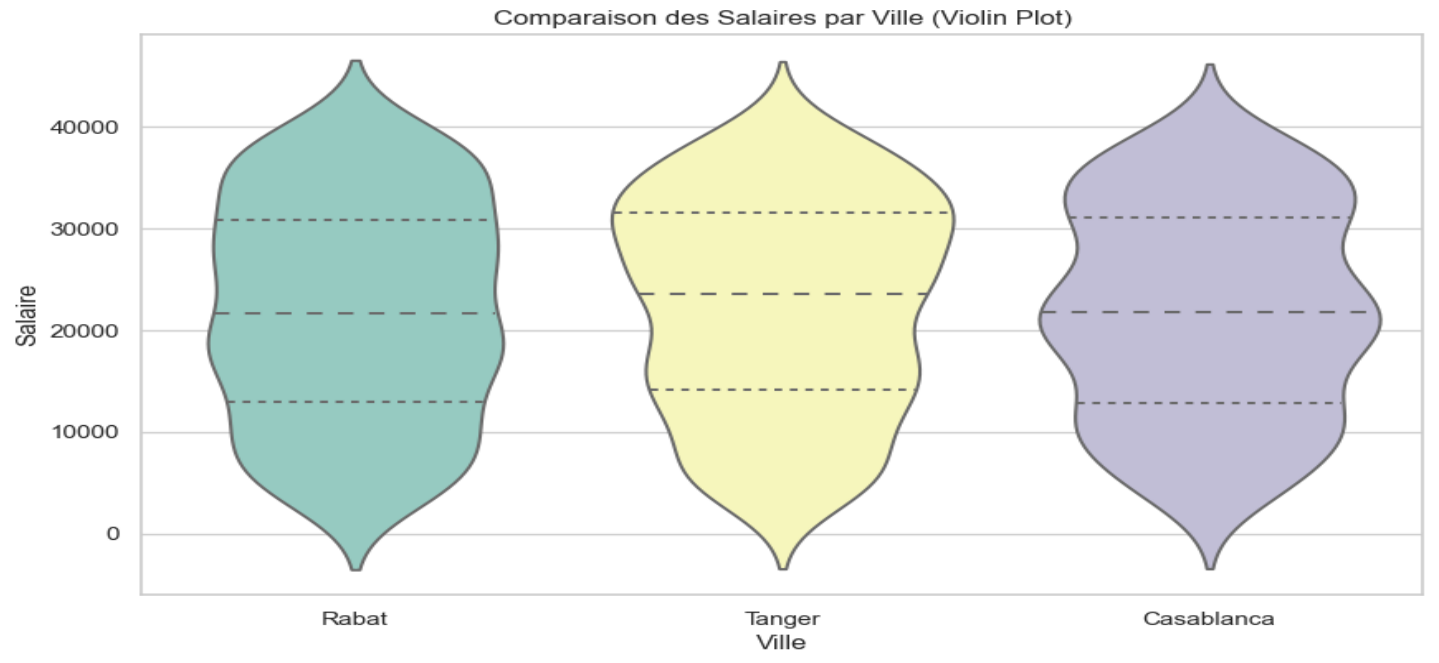

Partie 3 : Analyse des Relations (Bivariée)

Exercice 3.1 : Scatter Plot (Nuage de points)

Cherchez une corrélation entre l'Age et le Solde, tout en colorant les points selon la Ville pour voir s'il y a des clusters géographiques.

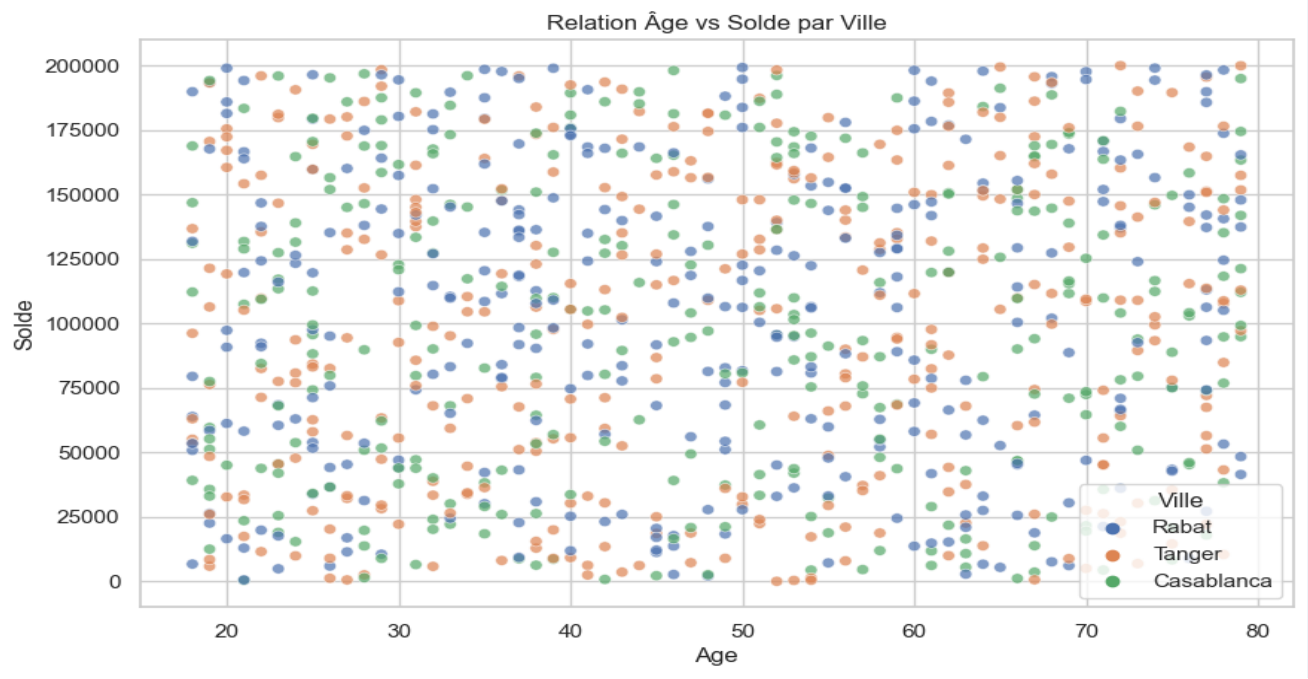

Exercice 3.2 : Regplot (Tendance Linéaire)

Existe-t-il un lien linéaire entre l'Age et le Score_Credit ? Tracez la ligne de régression.

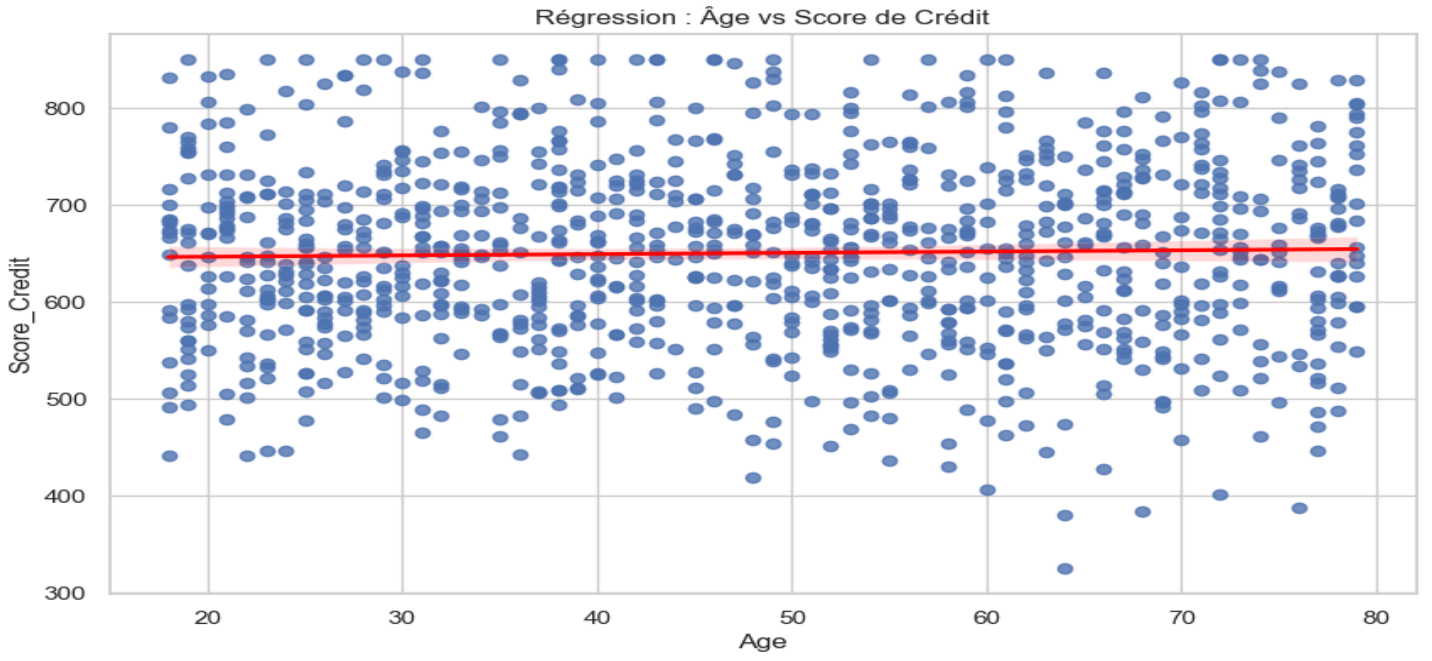

Note : La zone ombrée autour de la ligne rouge représente l'intervalle de confiance à 95%.

Partie 4 : Matrices et Vue d'Ensemble

Exercice 4.1 : Heatmap (Matrice de Corrélation)

Calculez la matrice de corrélation entre les variables numériques et affichez-la sous forme de carte thermique.

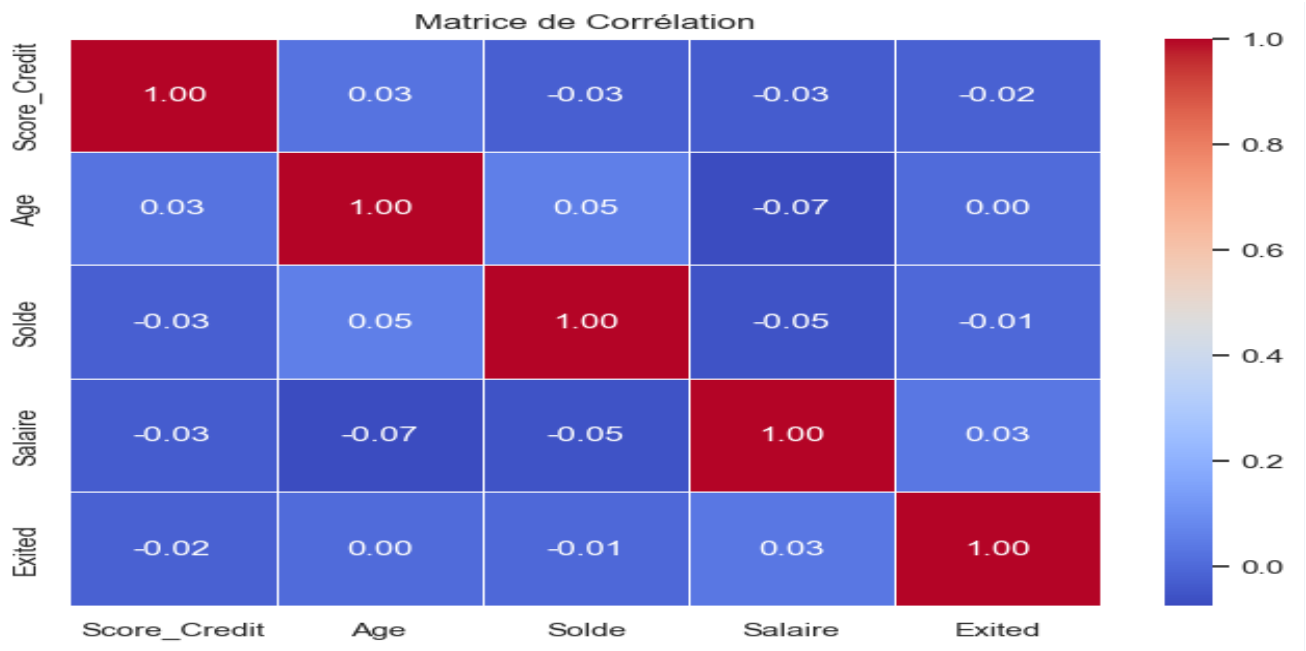

Exercice 4.2 : Pairplot (Vue Hélicoptère)
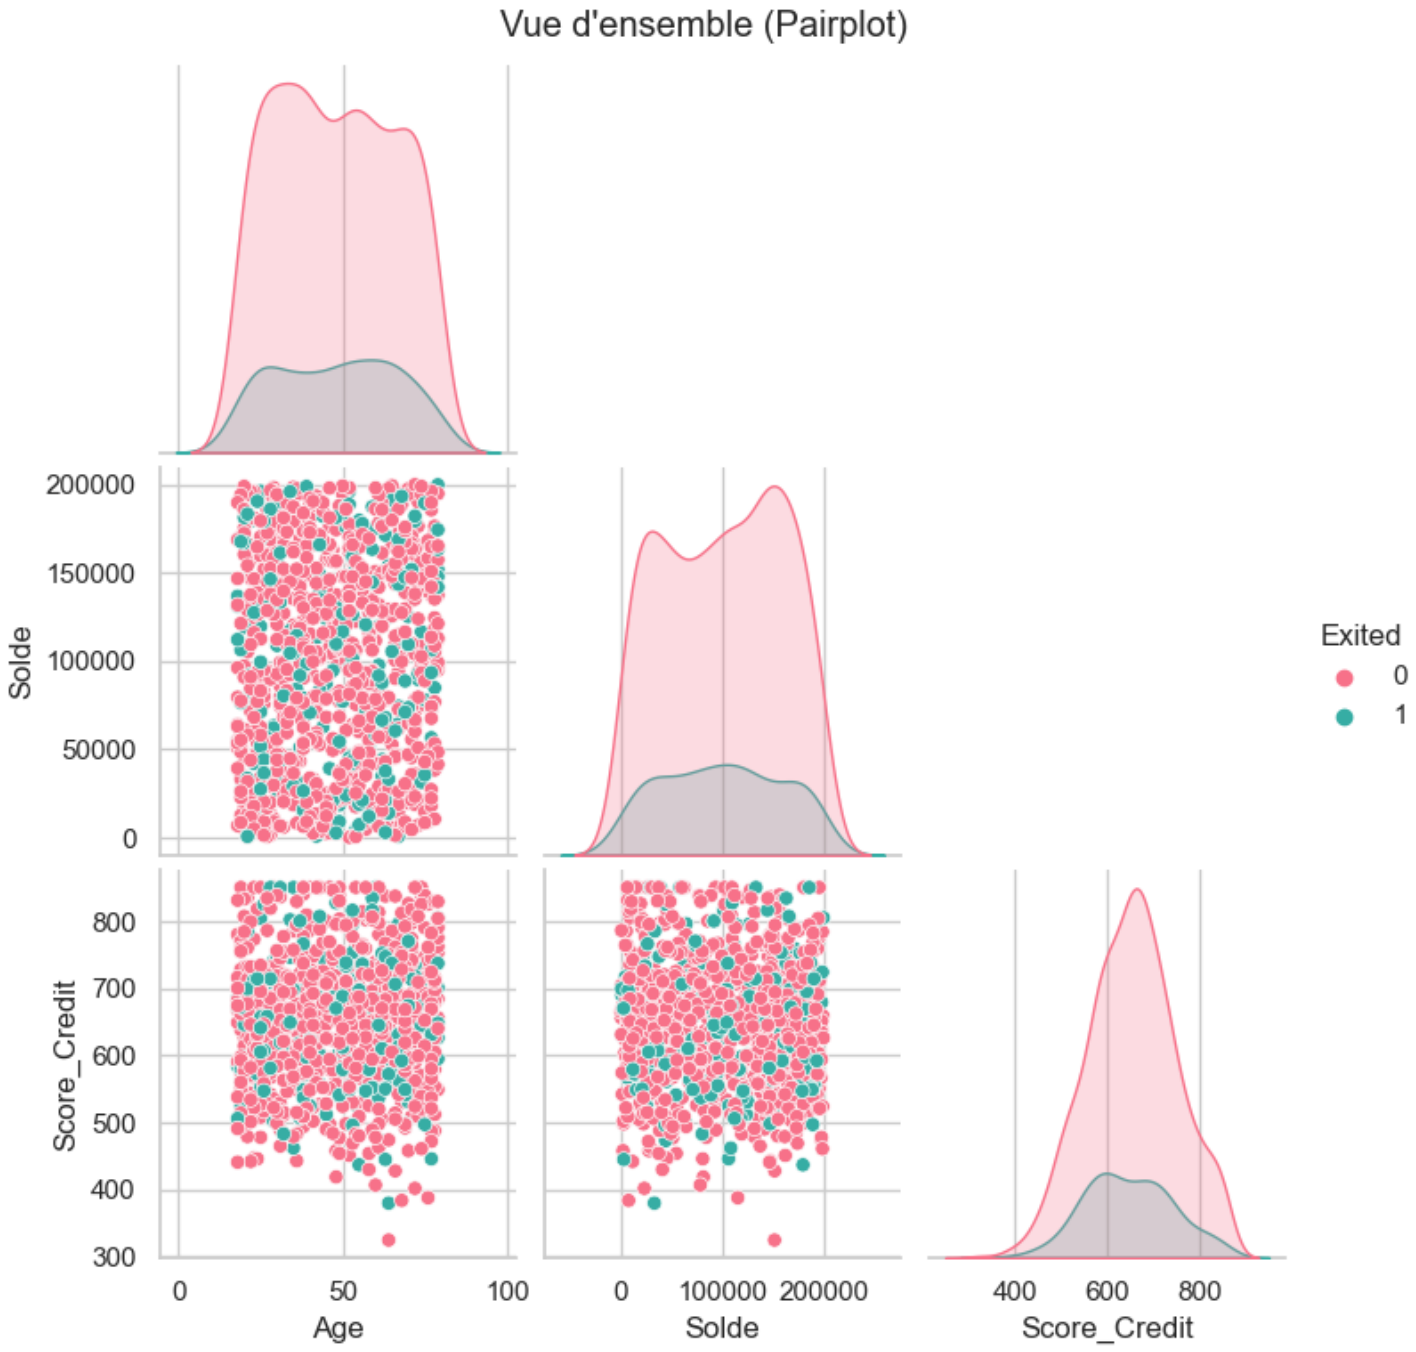
Enfin, générez une vue d'ensemble de toutes les relations possibles, colorées par la cible Exited.